UNIVERSIDAD DE BUENOS AIRES - 2026

Big Data y Machine Learning (527)

TRABAJO PRÁCTICO N° 2

UN PRIMER ENCUENTRO CON LA EPH

Fecha de entrega: viernes 10 de abril a las 13:00 h

Contenido*:* familiarización con la base de datos de la Encuesta Permanente de Hogares. Limpieza de datos, valores faltantes y análisis descriptivo. Medición de informalidad laboral.

Modalidad de entrega

- Cada grupo debe crear una carpeta llamada TP2 dentro de su repositorio público de GitHub.
- Dentro de esa carpeta deben incluir:
  - el código utilizado para resolver el trabajo práctico, indicando claramente a qué inciso corresponde cada parte;
  - el informe en PDF, con nombre **TP2_UBA_Grupo#.pdf** (donde **#** es el número de grupo), incluyendo gráficos e imágenes en el mismo archivo. El informe debe tener una extensión máxima de 5 páginas (sin apéndices) y se espera una redacción clara y precisa.
  - Slides de presentación grupal del informe en caso de ser sorteados.
- La última versión disponible en el repositorio al momento de la entrega será la que se considere para la evaluación. Por eso:
  - asegúrense de haber hecho *commit* y *push* con el mensaje: "Entrega final del TP" de la versión final antes de enviar el link de entrega en el campus;
  - no realicen nuevos cambios en el repositorio después de entregar.
- En la subsección de Entregas del campus virtual dentro de Actividades, usar como título **TP2_UBA_Grupo#**. Allí deben subir únicamente el informe, donde la primera página contenga el link a su repositorio de GitHub.
- **Cualquier detección de copia o plagio será sancionada.**

Parte I: Familiarizandonos con la base EPH y limpieza

La Encuesta Permanente de Hogares (EPH) es un programa nacional de producción sistemática y permanente de indicadores sociales que lleva a cabo el Instituto Nacional de Estadística y Censos (INDEC), que permite conocer las características sociodemográficas y socioeconómicas de la población. Uno de los indicadores más valiosos sobre el mercado laboral que pueden obtenerse con los datos de esta encuesta es la **informalidad laboral**.

1. Utilizando información disponible en la página del INDEC, expliquen brevemente cómo se identifica a las personas informales.

2. Entren a la página https://www.indec.gob.ar/ y vayan a la sección *Servicios y Herramientas → Bases de datos*. Descarguen la base de microdatos de la Encuesta Permanente de Hogares (EPH) correspondiente al primer trimestre de **2024** y **2025** en formato .xls, respectivamente (una vez descargadas, las bases a usar sonld `usu_individual_T124.xlsx` y `usu_individual_T125.xls`). En la página web, también encontrará un diccionario de variables con el nombre de "Diseño de registro y estructura para las bases preliminares (hogares y personas)". Descarguen el diccionario de cada año. En estos archivos se les indica qué significa cada variable que aparece en la base de datos, en particular, enfocarse en la sección de Diseño de registros de la base de Personas.

    a. Seleccione **20 variables de interés** para armonizar los formatos entre ambos años. **Entre las cuales tienen que estar: `CH04`, `CH06`, `CH07`, `CH08`, `NIVEL_ED`, `ESTADO`, `CAT_OCUP`, `EMPLEO`, `SECTOR`, `PP04C`, `PP04D_COD`, `P21`, `P47T`**. En este ítem se debe chequear consistencia de tipo de dato de cada año, de modo que las variables seleccionadas queden limpias/armonizadas en la **base final**. Sea cuidadoso ya que su trabajo futuro depende de esta limpieza. Tambien conserve todas las variables referidas a la identificación de personas como **`CODUSU`, `ANO4`, `TRIMESTRE`, `NRO_HOGAR`…, `PONDERA`.**

    b. Corrijan variables si notan valores sin sentido (como ingresos negativos) de acuerdo a la documentación de la EPH (puede ser una codificación de no respuesta de los individuos) y eliminen estos valores extraños de sus 15 variables de interés. Comenten en 1 párrafo el proceso de limpieza.

    c. Reporten y comenten en 1 párrafo usando una figura de *heatmap* el porcentaje de valores faltantes de las variables seleccionadas

para cada año (NA, o NaN en Python). También reporten en la figura el total de observaciones en su región para cada año.[1]

d. *Creación de variables:* Para las variables categoricas seleccionadas, cree **inteligentemente** variables dicotomicas binarias necesarias para trabajar con dichos datos. Recuerde renombrar dichas variables para que las etiquetas tengan sentido en el gráfico.

e. Actualice las variables **P21** y **P47T** con los ingresos de la ocupación principal y totales. Recuerde que los pesos de 2024T1 tienen un poder de compra distinto a los pesos de 2025T2 en el tercer trimestre. Convierta primero los ingresos de 2024T1 a pesos de 2025T1.

3. Uno de los grandes problemas del mercado laboral argentino es la informalidad. ¿Cuántas personas no respondieron cuál es su condición de actividad (`ESTADO`)? Guarden como una base distinta llamada `respondieron` las observaciones donde sí respondieron dicha pregunta (`ESTADO` $\neq 0$). Las observaciones con `ESTADO` = 0 guárdenlas en una base bajo el nombre `norespondieron`.

4. Quedense dentro de `respondieron` únicamente con las personas ocupadas (`ESTADO` = 1), ya que el análisis de formalidad aplica exclusivamente a quienes trabajan. Llamen a esta subbase `ocupados`.

Parte II: Primer Análisis Exploratorio

5. Realicen una matriz de correlación para 2024T1 y 2025T1 con las siguientes variables: `SECTOR`, `ESTADO`, `CAT_OCU`, `P21`, `P47T`, `NIVEL ED`, `CH04`, `CH06`, `CH07`, `CH08`. Utilicen alguno de los comandos disponibles en este link para graficar la matriz de correlación. Comenten los resultados. ¿Cambiaron mucho las correlaciones entre las variables de 2024 a 2025?

6. Realicen y comenten una tabla de estadistica descriptiva de todas las variables seleccionadas. La misma debe tener: número de observaciones, promedio, desvío estandar, min, p1, p25, p50, p75, p99 y max.

Parte III: Conociendo la informalidad laboral

Los siguientes incisos apuntan comparar 2024 con 2025.

[1] Para todos los gráficos que presenten, recuerde tener presentes los tres principios de visualización de datos discutidos en la Clase 1. Referencia: † Schwabish, J. A. (2014). An economist's guide to visualizing data. *Journal of Economic Perspectives*, 28(1), 209-234.

7. Siguiendo las definiciones de Maurizo & Monsalvo (2021), utilice la definición **asignada** de **informalidad** a su grupo. Expliquen brevemente las decisiones tomadas y las variables del diccionario que utilizaron para construir el indicador. Presente una tabla doble entrada con el porcentaje de trabajadores informales y formales, para el total de la población, mujeres y hombres en cada año. Comente los resultados en 1 parrafo.
8. *Visualización de Distirbución de Ingresos:* En un gráfico de 4 paneles muestre para formales e informales (con distintos colores:
    a. el histograma de la variable **P21**
    b. la distribución de kernel de **P21**
    c. el histograma de la variable **P47T**
    d. la distribución de kernel de **P47T**

    Comente las diferencias en las distribuciones para cada sector y limitaciones de las dos variables de ingreso utilizadas.

Parte IV: Herramientas de IA y reflexión final.

A continuación, se solicita explicitar el uso de herramientas de Inteligencia Artificial a lo largo del TP. Con el fin de promover un uso transparente, crítico y reflexivo de estas tecnologías, se deberá documentar lo realizado con las mismas y evaluar su aporte en este trabajo práctico.

1. Incluyan un Apéndice con todos los prompts de IA utilizados a lo largo del TP, copiados textualmente y en el orden en que fueron usados, y el nombre de la LLM utilizado (ChatGPT, Claude, Gemini, etc) .

2. Ítem final de reflexión (máximo 1 párrafo). Comenten cómo les ayudó la IA a programar: ¿en qué ítems fue más útil y en cuáles les resultó más difícil o menos efectiva? ¿Los ayudó en la interpretación de las consignas?

3. Por último, reporten aproximadamente el tiempo total (en horas) dedicado a la realización de este trabajo práctico.

Tabla de 'informalidad' disponibles por grupo

Antes de realizar el Trabajo Práctico, deben usar la definición de informalidad asignada según la siguiente tabla:

Definicion de informalidad segun Maurizo & Monsalvo (2021)	**# Grupo**
Upper-tier informal wage employees	1
Lower-tier informal wage emplyees	2
Informal self-employed	3

Referencias

Maurizio, Roxana; Monsalvo, Ana Paula (2021). *Informality, labour transitions, and the livelihoods of workers in Latin America*, WIDER Working Paper, No. 2021/19, ISBN 978-92-9256-953-2, The United Nations University World Institute for Development Economics. Research (UNU-WIDER), Helsinki, https://doi.org/10.35188/UNU-WIDER/2021/953-2